稠密检索的评测协议与指标选择

摘要：本文讨论本地文献问答系统中稠密检索的评测协议，重点不在模型结构，而在评测集构造、指标选择与结果解释三个容易被忽视的环节。我们的立场是：评测集的可信度决定了后面一切优化是否有意义，一个不可信的评测集会持续产出看起来精确实则随机的数字。

一章　评测集的构造原则。评测集必须由真实文档驱动：文档要经过与线上完全相同的解析与分块链路，答案片段要在真实分块中被定位出来，而不是由标注者手工指定块编号。这条原则的代价是构造更慢，收益是当解析或分块发生漂移时评测会立即失效并报警，而不是安静地继续给出高分。

二章　指标选择。召回率适合衡量证据是否进入候选集，平均倒数排名适合衡量首位命中的快慢，而　ｎＤＣＧ　需要分级相关性标注才能反映次级命中。只做二值相关标注时，排在第一名的次级相关段落与完全无关的段落对指标的贡献都是零，这会系统性地低估排序质量，进而误导调参方向。

三章　分级相关性的定义。我们把相关性分成三档：直接证据、强相关与弱相关。其中　ｇａｉｎ　等于三表示该段单独拿出来就能回答问题，这类段落构成必命中集合；强相关段落提供关键上下文但不直接给出答案，在排序中排到前面属于合理行为；弱相关段落只沾边，不应对排序产生正面贡献。标注时必须保证必命中集合里的段落取最高档，否则同一份标注会自相矛盾。

四章　负样本的特殊处理。语料中确实没有答案的问题称为负样本，它们的作用是检验系统是否会如实拒答而不是编造引用。负样本不产出任何检索指标键因为它们没有　ｇｏｌｄ，原因是计算召回率需要已知的正确集合，而负样本恰恰没有任何相关内容。把它们以零分计入分母会显著拉低整体指标并掩盖真实退化，因此聚合函数必须只平均实际存在的指标键。

五章　指标饱和问题。当候选总数小于截断位次时召回率恒为一。这个约束在小语料上尤其容易触发：如果整个语料只切出四五个块，而评测又在截断位次十的位置上计算召回率，那么无论检索质量如何变化，召回率都会稳定地等于一，指标完全失去分辨力。判断是否饱和的方法很简单：看候选总数与截断位次的关系，而不是看指标值有多高。

六章　样本量与结论强度。多文档场景的样例往往最少，而它恰恰是精度最容易退化的一类。在只有两三条样例时，任何精度差异都落在噪声范围内，样例数量不足时指标只有方向可信而数值不可信。因此我们要求：在据以修改检索算法之前，先确认该类样例的数量足以支撑结论，否则优化的是噪声而不是系统。

表　1　指标与适用条件。召回率　需要已知正确集合　；平均倒数排名　关注首个命中位次　；归一化折损累计增益　需要分级标注　；精确率　对候选总数敏感　。

七章　可复现性与新鲜度。用例集指纹变化后必须重跑评测否则报告视为过期。实现方式是给用例集内容算一个内容指纹并写入报告，评测前的门禁把当前指纹与报告里的指纹比对。这样改评测集这件事本身会被记录，而不是通过悄悄替换样例把分数“调”上去。

八章　常见误用。用硬编码的内联短句构造评测集是危险的，因为它绕过了解析、换行重排、语义分块与表格公式处理，测出来的高分不代表真实可用。合成的内联集只适合做指标公式回归与秒级链路自检，不应作为对外结论的依据。

十章　分层统计。只报一个总体指标是不够的，因为它会把不同难度的用例混在一起，一处退化可能被另一处改善抵消。因此报告必须按　ｋｉｎｄ　分层给出样本数与指标，并在样本数过小的分层上显式标注不确定，而不是照常给一个看似精确的数字。

十一章　分母口径。指标的分母必须只包含真正参与该项指标计算的用例。负样本不进入检索指标的分母，判官失败的用例也不应进入答案层指标的分母，否则一次接口超时就会表现为质量下降，把偶发故障误读成模型退化。

十二章　人工复核。自动生成的标注只能作为候选，不能直接充当标准答案。复核的重点有三处：最高档是否确实单独可回答、有没有漏标的相关段落、以及泛问类问题是否存在多个最高档而只标了一个。

十三章　标注一致性。如果标注者之间都无法就相关性达成一致，那么用这套标注去调算法就没有意

义。因此需要抽样算出标注者与判官的一致度指标，并在低于阈值时先修判据、而不是先改检索实现。

十四章　版本化。评测集本身需要版本号与变更记录，改动要说明为什么改，并且保留旧版本以便对照。把评测集当作可以随时修改的临时文件，是让历史指标失去可比性的最快方式。

十五章　与线上同源的口径。设备的种类、线程数、语料规模、候选数、功能开关、以及加速档位都会改变延迟与指标，因此报告必须把这些口径逐项记录，否则两份数字的差异根本无法归因。

十六章　检索层与答案层的分离。检索层回答证据有没有被找到，答案层回答结论有没有忠于证据，两者不能混在一个指标里。检索好而回答差的系统，与检索差而回答谨慎的系统，需要完全不同的修复方向。

十七章　忠实度判定。忠实度衡量回答中的每个断言是否能在给定证据里找到支持。判定不应看回答是否与参考答案措辞相似，而应看断言与证据之间是否存在蕴含关系，否则一个措辞不同但完全正确的回答会被判为不忠。

十八章　拒答判定。当证据不足时，正确的行为是明确说明缺少什么，而不是给出猜测。因此答案层评测必须包含不可答的用例，并把如实拒答记为正确；把拒答一律记为失败，会系统性地奖励编造。

十九章　判官的自指风险。用同一个模型既生成答案又判定答案，会得到系统性偏乐观的结果，因为该模型倾向于认可自己偏好的表述。因此判官必须来自与被评模型不同的厂商，或至少在报告中显式标注同源这一事实。

二十一章　基线冻结。评测集一旦确定为基线，就不应在比较过程中被替换，因为所有历史结论都建立在它之上。基线一旦冻结就不应在比较过程中被替换。需要修正标注时应当发布新版本并重跑全部历史对照，而不是就地改掉。

二十二章　样本量与置信。指标是点估计，样本少时它的波动区间很大。因此　样本量不足时应当报告置信区间而不是只报点估计。具体做法是把逐例得分当作观测，算出均值的标准误；当两次实验的差值小于两倍标准误时，不应宣布任何结论。

二十三章　显著性检验的边界。逐例得分并不严格独立，同一文档的用例彼此相关，因此常规检验会略微高估显著性。实践上把它当作一个上界：如果连上界都不显著，就完全没有必要继续讨论这组差异。

二十四章　评测运行的工程化。评测脚本本身也要纳入版本控制。评测脚本会被反复运行与修改，它的口径漂移和被测系统一样会污染结论，因此它需要版本号、变更记录与回归测试，而不是当作一次性的临时脚本。

二十五章　运行成本。评测的开销主要在三处：文档编码、每例检索与重排、以及答案层判官。前两者可以本地完成且可缓存，第三者需要外部调用，因此答案层评测应当采样而不是全量，并把采样口径写进报告。

二十六章　缓存与可比性。为加速而缓存编码结果时，必须确认缓存键覆盖了分块参数与分词设置。若缓存键只包含文件内容指纹，那么改了分块参数之后会继续命中旧索引，评测会稳定地给出上一版的结果，而这一现象完全不会报错。

二十七章　冷启动与并行。首次运行需要加载模型，耗时远高于稳态；并行化只在候选彼此独立时有效，而重排阶段是批推理，并行反而争抢同一块显存。因此并行化的收益集中在文档编码阶段。

二十八章　指标漂移的检测。即便用例集固定，语料解析或分块实现的变更也会让指标漂移。因此每次改动解析链路之后都应当重跑基线并对比，把“指标变了”这件事变成一次显式的确认，而不是等到用户反馈才发现。

二十九章　报告的可读性。一份评测报告应当让人在两分钟内回答三个问题：用了哪套用例集与哪套口径、总体指标如何、以及哪一类用例最差。缺少任何一项，报告就只能被信任而不能被使用。

三十一章　用例的独立性。同一文档派生的多条用例彼此相关，因此它们对指标的贡献并不独立。把相关性很强的用例大量堆进同一类，会让该类的指标看起来稳定，而实际上只是同一份证据被反复计

数。

三十二章　难例的采集。难例最好从真实失败中采集，而不是凭想象构造。具体做法是先跑一轮，把没有命中的用例记录下来，再看它们的共同特征，据此补充同类难例；这比凭空设想「用户可能会问什么」有效得多。

三十三章　指标的稳定性。同一套用例连续跑两次，指标应当基本一致；若波动明显，说明存在未受控的因素（缓存、并行顺序、随机种子）。在把任何差异归因于算法之前，先确认重复运行的波动幅度小于该差异。

三十四章　结论的表述。报告应当区分「观察到的事实」与「据此提出的解释」。前者可以写进结论，后者应当标注为推测并给出验证方式，否则一份几个月后回看的报告会让读者分不清哪些是被证实的。

三十五章　结论。评测协议的核心不是指标公式的复杂度，而是评测集本身是否可复现、是否覆盖难例、是否对退化敏感。只有在这三点成立之后，检索质量的比较才有意义。