长文改稿中的格式保真与段落寻址

摘要：针对 Ｗｏｒｄ 长文的机器辅助改稿，本文讨论段落级寻址、修订留痕与格式保真三件事，并给出在本地实现的工程取舍。

１ 段落寻址。系统为每个正文段落分配稳定编号，写作 Ｐ 加序号，模型只能通过这些编号提出修改，避免出现无法定位的自由文本。

２ 修订留痕。所有改动以插入与删除两种修订形式写入文档，用户在 Ｗｏｒｄ 中可以直接接受或拒绝，而不必对照两份文件。

３ 格式继承。最初的实现把整段原文标记为删除、再追加一段新文本，导致整段退化为默认字体与字号；修正后改为逐段运行块对齐，把变化部分单独包裹为修订，未变化部分原样保留。

４ Ｒｕｌｅｓ ｆｏｒ ｎｅｓｔｅｄ ｓｔｒｕｃｔｕｒｅｓ．Ｗｈｅｎ ａ ｐａｒａｇｒａｐｈ ｃｏｎｔａｉｎｓ ｎｅｓｔｅｄ ｅｌｅｍｅｎｔｓ ｓｕｃｈ ａｓ ｉｎｓｅｒｔｉｏｎｓ ｉｎｓｉｄｅ ｈｙｐｅｒｌｉｎｋｓ，ｔｈｅ ｉｍｐｌｅｍｅｎｔａｔｉｏｎ ｆａｌｌｓ ｂａｃｋ ｔｏ ｗｈｏｌｅ ｐａｒａｇｒａｐｈ ｒｅｐｌａｃｅｍｅｎｔ，ｂｅｃａｕｓｅ ｐａｒｔｉａｌ ｒｅｗｒｉｔｉｎｇ ｔｈｅｒｅ ｗｏｕｌｄ ｃｏｒｒｕｐｔ ｔｈｅ ｍａｒｋｕｐ．

５ 表格与页码。表格内的段落使用独立编号前缀，而缺少物理页码的文档在引用核验时只报可疑项，不报弱提示，避免提示疲劳。

公式 １ 保真度定义：保真度等于未被改动的运行块数量除以运行块总数。

表 ２ 操作类型与语义。替换 ｒｅｐｌａｃｅ ；追加 ａｐｐｅｎｄ ；后插 ｉｎｓｅｒｔ＿ａｆｔｅｒ ；删除 ｄｅｌｅｔｅ 。

６ 原子写入。文档保存采用先写临时文件再原子替换的方式，并保留最近五份备份，防止写入中断导致文件损坏。

７ 结论。把改稿约束在段落级、并把格式保真作为一等目标，可以让机器改稿的结果直接进入人工审阅流程。

８ 无效回复机制。模型有时会返回格式正确但不包含任何修改意见的内容，这类回复必须被识别并记为空转，而不是当作一次成功的改稿计入进度。

９ 差异对照。系统为用户同时提供图文视图与结构视图：前者用于阅读成稿效果，后者用于逐段核对改动来源，两者共享同一份底层数据。

１０ 批量改写的边界。一次性提交过多段落会让模型的注意力分散，实测表明按章节分批提交时保真度更稳定，代价是需要保存中间状态。

１１ 样式表处理。文档样式表与正文是分离的，若替换段落时未继承原段落的样式引用，即使文本正确也会在渲染时出现字体跳变，因此样式引用必须随运行块一并处理。

１２ 图片与题注。图片本身不参与文本改写，但其题注编号需要与正文引用保持一致；改写正文后应当重新校验编号，否则会出现图文不一致。

１３ 修订冲突。当同一段落被连续两次改写时，第二次改写必须基于第一次的结果，而不是原始文本，否则前一版的修订会被静默覆盖。

１４ 引用核验。系统对引用逐一核对页码与段落是否存在，对无法核验的引用单独列出可疑项交人工确认，不做自动删除。

１５ 性能取舍。整篇文档的运行块扫描是最耗时的环节，因此在改写前先计算受影响范围，只扫描相关段落，可以显著降低等待时间。

１６ 局限性。当前实现依赖段落编号的稳定性，若用户在外部编辑文档中插入或删除段落，编号会整体错位，需要重新建立寻址。

１７　修订的可见性。插入与删除两种修订在　Ｗｏｒｄ　中呈现方式不同，删除内容默认以删除线显示而不消失，这让用户能够确认被移除的原文，因此在实现中不应当用真正的删除操作来替代删除修订。

１８　段落合并与拆分。改稿请求有时要求合并两段或把一段拆开，这类操作会改变后续所有段落的编号，因此必须在完成后重新编号并刷新寻址表，否则后续引用会指向错误的段落。

１９　中英混排的处理。文档中存在中英混排时，字数统计与显示宽度并不一致，若按字符数限制改写长度，英文段落会被切得过短，因此长度约束应当按语言分别设定。

２０　脚注与尾注。脚注编号与正文引用相互依赖，改写正文后若不同步调整脚注顺序，会出现编号跳号，故脚注被排除在自动改写范围之外。

２１　审阅轮次。改稿通常不是一次性完成的，系统保存每一轮的修订与批注，使得用户可以回到任意一轮继续，而不是只能接受或拒绝最终结果。

２２　段落级最小改动原则。改写应当只触碰必要的运行块，把整段重写的做法虽然实现简单，但会把作者原有的措辞习惯一并抹掉，这也是格式保真指标被单独提出的原因。

２３　空转识别与提示。当模型连续返回不含任何修改的回复时，系统给出明确的提示而不是继续重试，因为这类空转通常意味着请求本身缺少可操作的指令。

２４　模板与样式继承。使用模板创建的文档带有预设样式，改写时若直接套用正文默认样式，会让标题与正文的层级关系丢失，因此必须读取并沿用原段落的样式标识。

２５　结束语。改稿系统的价值不在于改得更多，而在于让每一处改动都可定位、可撤销、可核对，这三点决定了它能否真正进入人工审阅流程。

２６　编号稳定性与重编号策略。文档结构变化后，最稳妥的做法是保留旧编号到新编号的映射，使既有批注仍能指向正确位置，而不是简单地从当前顺序重新编号。

２７　批注与修订的区分。批注用于提出疑问，修订用于实际改动，两者在文档中承担不同职责；把疑问直接写成修订会让用户误以为内容已被修改。

２８　段落属性的保留。段落具有对齐、缩进、行距等属性，改写时若只替换文本而不复制属性，视觉上会出现突兀的变化，因此属性必须与运行块一同处理。

２９　超长段落的处理。超过一定长度的段落会超出模型的稳定处理范围，实践中按语义切分为若干子段分别处理，再合并结果并保持原有段落边界不变。

３０　表格内改写的限制。表格单元格内的文本改写会牵动列宽与对齐，因此默认只处理纯文本替换，不调整表格结构，结构层面的调整交由人工完成。

３１　文档打开状态的冲突。文档被外部程序占用时写入会失败，系统检测这一状态并提示用户关闭，而不是反复重试或静默放弃。

３２　备份与回滚。每次写入前生成备份，并允许用户回滚到任意一次备份；原子写入只能保证文件不损坏，不能保证语义上符合预期，因此两者都需要。

３３　结束语（补充）。段落寻址、修订留痕与格式保真三者互相依赖：缺少任何一个，机器改稿的结果都无法直接进入人工审阅。

３４　人工复核的定位。机器改稿的输出应当被定位为候选，而不是结论；系统的职责是降低人工核对的成本，而不是替代判断。

３５　请求的可操作性。改稿请求若只给出模糊方向，模型难以产出可用结果；实践中要求请求至少指明目标段落与期望变化，否则宁可提示用户补充，也不猜测意图。

３６　术语一致性。文档中的专业术语在改写时不应被同义替换，因此需要维护术语表并在改写时保护其中的词条，避免引入不一致的表述。

３７　结束语（终）。把改稿约束在可定位、可撤销、可核对的范围内，机器产出的每一处改动才具备进入正式审阅流程的资格。

３８　修订密度的控制。一份文档中修订过于密集会让人工审阅难以进行，因此系统对单次提交的段落数量设定上限，并提示分批进行。

３９　与检索的配合。改稿请求常常需要先定位证据所在的段落，此时检索提供候选段落，模型再在此范围内提出修改，把开放式的改写收敛为有依据的局部改动。

４０　输出的可核查性。每一处改动都应附带改动理由与依据段落，缺少理由的改动即便文本更通顺，也会增加人工核对的成本。

４１　结束语（终补）。可定位、可撤销、可核对，既是改稿系统的设计约束，也是评价其输出是否可用的三条判据。