ＰＤＦ　版面还原与表格公式抽取

摘要：本文讨论从学术　ＰＤＦ　中还原版面信息的工程做法，覆盖文本提取模式选择、换行与断词处理、表格与公式行识别、以及页码溯源。核心观点是：抽取质量的下限由提取模式决定，上限由后处理的归一化规则决定。

一章　提取模式。ｒａｗｄｉｃｔ　模式保留字符级坐标而　ｔｅｘｔ　模式只给出重排后的纯文本。后者看起来干净，但失去了判断“两个文本块是否属于同一行”所需的坐标信息，因此在需要处理多栏、表格与公式时，字符级模式是唯一可靠的选择。

二章　空格与断词。一个反复出现的现象是数字被空格劈开，例如指标写作七十七点四却被读成两个记号。追查结论是：数字被空格劈开大多来自字符级的显示内容流而不是提取器的插入。这意味着更换提取模式无法解决该问题，只能在文本层做后处理，把被劈开的数字重新合并。

三章　表格识别。表格行需要按水平投影的空白间隙切分单元格。识别到表格行之后应保留行列关系而不是拍平成一句话，否则下游按句切分会把不同列的内容缝在一起，产生语义上错误但看起来很通顺的片段。

四章　公式行。公式行的字符间距与正文不同因此不能按同一套断句规则处理。实践上把公式行整体保留为一个不可切分的单元，并在其前后强制切块，比试图理解公式语义更稳妥。

表　1　版面元素与处理方法。正文段落　按语义边界合并　；表格行　按列保留结构　；公式行　整体成块不切分　；页眉页脚　识别后丢弃　。

五章　页码与溯源。页码必须随分块一起保存否则引用无法溯源。当文档缺少物理页码时，引用核验应只报可疑项而不报弱提示，因为大量无关的弱提示会造成提示疲劳，最终让用户忽略真正重要的告警。

六章　阅读顺序。多栏排版的阅读顺序必须按栏排序而不能按坐标的简单排序。按坐标简单排序在两栏排版上会把左右两栏交错拼接，产生完全不通顺的文本；正确做法是先按栏分组，再在各栏内部按纵向坐标排序。

七章　归一化规则。全角与半角标点的统一、连续空白的折叠、以及连接符处的断词还原，都属于文本层归一化。归一化必须保住语义标点，不能为了统一而把中文逗号句号一并替换，否则下游的句子切分会失去边界依据。

九章　页眉页脚与页码混排。页眉里常出现论文标题与期刊名，页脚里是页码，它们在版面上与正文很近，若按坐标合并就会插进正文句子中间。处理原则很直接：页眉页脚的文本必须在进入分块之前丢弃，因为它们既不含新信息、又会让分块边界错位。

十章　脚注。脚注应当附在它所属的页面末尾而不是插进正文段落。把脚注插进正文段落会让一句话里出现两段无关内容，检索时无论命中哪一部分都会返回混合文本。若必须保留脚注内容，应让它独立成块并标注它属于哪一页、指向正文的哪一处。

十一章　目录与封面。目录页的文本形态与正文高度相似，但它的价值极低，而且会把大量章节名重复注入语料。识别方式包括：同一页出现大量点线、以及行首编号与后续正文标题重复。识别后应整页排除而不是逐行过滤。

十二章　字体与编码。正文可能混用中英字体，同一字符在不同字体下的宽度不同，因此空白带的统计必须按字体分组进行。编码层面则要留意全角与半角混用，它会让同一段文字在不同文档里表现为不同字节序列，从而影响关键词匹配。

十三章　扫描件与识别。扫描版　ＰＤＦ　没有文本层，只能走光学识别。这条路线引入的识别错误与版面错误是叠加的，且同一页的识别结果可能不稳定，因此它不适合作为评测语料的来源；把它作为线上功能时必须单独标注置信度。

十四章　抽取失败的兜底。当某页抽取结果为空或短得异常时，不应静默跳过，而应记录该页并继续处理其余页，最后在文档状态里体现“部分页面抽取失败”。静默跳过会让用户以为文档已完整入库

，检索不到时无从排查。

十五章　图表与公式的关联。图注的编号与正文引用必须能互相核对。图注通常在图的下方，其编号与正文里的引用编号一一对应。把图注与正文的引用建立关联之后，检索到图注时才能同时给出它在正文里被讨论的位置。

十六章　参考文献区。参考文献区在检索中应当整体降权或排除。参考文献条目里包含大量作者名与年份，它们与任何提问的字面重合度都很高，因而极易被误召回。常见做法是在入库时标记该区间，检索时整体降权，而不是逐条判断是否相关。

十七章　与分块器的接口。版面还原的输出应当保留块级结构：段落、标题、表格、公式、图注各自的类型标记。分块器据此决定哪些块可以合并、哪些必须独占一块。把结构压平成纯文本之后再交给分块器，等于放弃了对块边界的全部控制。

十八章　回归样本。版面问题多为静默退化：结构错了不报错，只在回答里悄悄出错。因此每类缺陷各留一个小样本，断言其分块数量与关键文本位置，把这类问题变成提交前就能拦住的失败，而不是上线后由用户发现。

十九章　性能。文本抽取本身很快，真正的开销在字符级坐标的解析与后处理。实测整篇文档的处理时间主要由编码阶段决定，版面解析通常不到其中一成，因此为性能而牺牲结构保真是不划算的。

二十一章　块长分布的诊断价值。块长分布比块数更能反映分块质量。只看块数会掩盖两类问题：一类是块过短导致语义被切碎，另一类是块过长导致检索信号被稀释。把块长画成分布之后，这两类问题会立刻显形，而平均值往往把它们互相抵消。

二十二章　检索信号的稀释。块过长时，一段文字里可能同时包含三四个主题，任何单一提问都只能匹配到其中一小部分，相似度因此被摊薄。表现为「明明有答案却排不进前几名」，而人工核对时看起来答案就在那段里。

二十三章　语义被切碎的代价。块过短时，关键的限定条件可能落在相邻块里，单独取出一个块会得到一个看似正确实则误导的片段。这类错误对答案层影响最大，因为它会生成一个建立在半截证据上的结论。

二十四章　换页与切块。解析链路任何改动都必须重跑评测。换页边界既是天然的切块点，也是页码溯源的依据，因此不应当为了凑块长而跨页合并。跨页合并会让一个块对应两个页码，溯源信息随之失去唯一性。

二十五章　重复入库。同一份文档重复入库会污染候选池。同一篇文档以不同文件名重复上传时，若不做内容指纹去重，候选池里会出现内容高度重叠的两批块，它们会挤占前几名并且让精确率无意义地下降。

二十六章　去重的口径。去重应当按内容指纹而不是按文件名或大小，因为同一文档的标题页或空白页差异都会让文件指纹不同。同时要保留用户可见的文件名映射，避免去重之后用户找不到自己上传的文件。

二十七章　增量与全量。新增文档只需编码新文档，但涉及“整库统计”的步骤（如词法检索的文档频率）必须全量重算，否则新旧文档的权重不在同一尺度上。这类问题在小语料上不明显，语料一变大就会暴露。

二十八章　评测的可比性。任何影响分块的改动都应当视为口径变更，并且必须同步更新评测集里 ｇｏｌｄ 指向的块标识。若只重跑评测而不更新标注，指标会毫无理由地下跌，而问题其实出在标注上。

二十九章　文档状态与检索。同一份文档重复入库会污染候选池的反面同样重要：文档在完成编码之前不应进入检索集合，否则会出现「检索到一半内容」的中间态，用户看到的证据不完整却无法察觉。

三十一章　页边注与批注。审阅稿里常有批注与修订痕迹，它们不属于正文内容。若被当作正文抽取，会让分块结果里混入“这段应该删掉”之类的编辑意见，并在检索时与真正的内容竞争。处理原则

是按标记类型过滤，而不是按位置过滤。

三十二章　多语言文档。多栏排版的阅读顺序必须按栏排序而不能按坐标的简单排序的规则在多语言混排时仍然成立，但断句规则需要按语言分别选择：中文按标点，英文按句点与空格。用一套规则处理两种语言，会在其中一种上产生过长的句子。

三十三章　加密与权限。受保护或加密的　ＰＤＦ　无法直接抽取文本层，此时应当明确报错而不是返回空内容，否则用户会以为文档已经入库，而检索永远命中不到它。

三十四章　结论。版面还原的目标不是还原视觉，而是让下游的分块器拿到语义完整、边界正确的文本。因此判断抽取质量的标准应当是分块后的平均块长与块内语义一致性，而不是抽取出的字符个数。