面向本地文献库的混合检索增强生成系统

摘要：本文面向本地优先的单用户文献研读场景，提出一套混合检索增强生成方案，在不依赖外部服务的前提下提升论文问答的事实一致性。

1　引言。学术文献的问答对证据定位要求很高，纯生成模型容易给出文档中并不存在的结论，因此检索质量直接决定了最终回答的可信度。

2　分块策略。系统按语义边界把正文切分为三百到五百字的块，过小的块会丢失上下文，过大的块会稀释检索信号。

3　检索通道。系统同时使用三条召回通道：稠密向量检索负责语义相似，BM25　负责关键词命中，稀疏向量兼顾两者，其中　BM25　使用　jieba　按词切分以适应中文。

4　融合策略。三路召回结果通过　RRF　融合为统一排序，融合常数取　60，该值越大则排名差异被压得越平缓。

5　重排。融合后的候选交给交叉编码器重排，重排模型同时读取查询与候选文本，因此精度高于仅比较向量的方式，但耗时显著更长。

6　性能观测。实测重排阶段占单次检索总耗时的百分之九十七，是唯一的性能瓶颈；把候选数从五十降到二十后，前五名结果完全一致，而重排耗时下降约六成。

表　1　各阶段耗时（单位：毫秒）。编码　47　；混合召回　58　；重排　1444　；合计　1549。

7　缓存。系统对查询结果做容量为　32　的先进先出缓存，在索引发生变更时整体失效，避免旧结果污染新索引。

8　失败语义。系统严格区分两种情况：检索服务不可用属于系统故障，而检索结果为空表示文档中确实没有相关内容，两者对用户的提示完全不同。

9　结论。混合检索配合重排可以在本地设备上取得可用的检索质量，但必须以真实文档构造的评测集来验证，否则指标不具备参考价值。

10　评测协议。评测集应当由真实文档生成，并覆盖逐字命中、改写提问、多证据与负样本四类情形。只测其中一类会让指标看起来很好，却无法反映真实使用中的表现。

11　冗余与去重。多路召回天然会带来重叠结果，若不去重，同一段文本可能占据前五名中的多个位置，等效于减少了实际可用的证据数量。

12　引用溯源。每个分块都必须保留页码与文档标识，否则答案无法回溯到出处，用户也无法判断引用是否与原文一致。

13　索引更新。文档新增或删除后应当增量更新索引，而不是整体重建；整体重建在文献库较大时会产生明显的等待时间，并且在重建过程中无法提供检索服务。

14　中英混排。学术文献普遍存在中英混排现象，分词器必须同时处理两种语言：按字符切分会让英文单词失去边界，按空格切分则会把整段中文视为一个词。

15　成本模型。检索成本由三个部分构成：查询编码、混合召回与重排。其中查询编码的耗时与文档规模无关，属于固定成本；重排的耗时与候选数量成正比，是唯一可以通过裁剪候选显著降低的部分。

16　本地化与隐私。系统被设计为完全本地运行，文档内容与检索请求均不出本机，这让它在处理未公开稿件时具备可用性；代价是所有计算都必须在本机设备上完成。

17　失败恢复。检索链路的任何一环失败都应当被明确上报，而不是静默返回空结果；用户需要区分系统故障与文档中确实没有答案这两种情况。

18　局限性。本方案依赖交叉编码器重排，因此在候选规模较大时延迟会显著上升；此外对表格与公式的处理仍然有限，这些内容在抽取阶段容易被压成一维文本而丢失结构。

１９　相关工作。与端到端的生成式问答相比，本方案把证据定位与答案生成分离，牺牲了一定的灵活性，换来的是可核查的引用与更稳定的事实一致性。

２０　未来工作。下一步计划引入文档结构感知的分块策略，并把评测集扩展到表格与图注等结构化内容，使质量评估覆盖更多真实形态。

２１　分块边界的实证。按固定长度切分会让跨段落的论证被拆散，而完全按段落切分又会让短段落稀释检索信号；折中做法是设定目标长度并在句子边界收口，使绝大多数块落在目标长度的邻域内。

２２　融合常数的敏感性。融合常数决定排名差异被压缩的程度：取值过小时，单通道的偶然高分会被放大；取值过大时，各通道的排名差异失去意义。实测表明在候选规模较小时，结果对这一常数并不敏感。

２３　候选裁剪的位置。裁剪发生在重排之前还是之后，决定了省下的是哪一部分成本：放在重排之前可以显著降低延迟，代价是可能丢掉需要深层比对才能识别的证据。

２４　长文档的召回衰减。当单篇文档的块数远超候选上限时，同一文档内部会形成竞争，正确块可能被同文档的相似块挤出前五名，这也是多证据提问比单证据提问更容易漏检的原因。

２５　查询改写的作用与代价。把口语化提问改写为检索式可以提升召回，但改写本身会引入一次模型调用，并且可能偏离用户原意；在问题已经足够具体时，改写的收益通常不足以抵消其成本。

２６　向量维度与存储。稠密向量的维度直接决定索引体积与检索时的内存占用，在单机部署中需要在召回质量与常驻内存之间取舍。

２７　索引一致性。文档被删除后，其向量与分块必须一并清理，否则检索会命中已经不存在的内容，表现为引用指向空文档。

２８　检索与生成的边界。检索只负责提供证据，生成只负责组织语言；把事实判断交给生成模型会引入无法核查的内容，因此系统提示词被明确限定为只能依据资料回答。

２９　可复现性。同一份评测集在相同配置下重跑，检索结果应当完全一致；若出现差异，说明某处引入了不确定性，而这类不确定性会让跨版本的指标比较失去意义。

３０　结束语。上述工程取舍的共同点是：先用可复现的评测确认问题确实存在，再投入改动，并在改动后重新测量同一份评测集，而不是凭直觉调整参数。

３１　阈值与度量的配套。任何阈值都只在其度量口径下有意义：更换估算方式之后，原有的阈值会静默地改变含义，因此二者必须成对调整并同时记录。

３２　负样本的价值。只统计找到了多少证据会掩盖一个方向的问题，即系统在资料不足时是否如实说明；负样本的存在使这一维度可被测量，没有它，答案层的安全边界就没有证据。

３３　判官与生成模型的分离。用同一模型既生成答案又评判答案，会让评判倾向于认可自己的表述，因此评判应当由不同来源的模型完成，并用人工标注校验评判本身是否可靠。

３４　一致性指标的用法。一致性指标衡量的是超出随机的一致程度，当两侧判定都没有区分度时该指标无定义；这时应当报告错误率及其置信上界，而不是把算不出的指标写成一个数字。

３５　样本设计的先行条件。在给指标设定目标之前，必须先确认样本中确实存在可能被判错的案例，否则无论系统表现如何，得到的都只会是一个没有分辨力的结果。

３６　指标上限的核算。精度类指标的上限由标注中的相关结果数量与截断位次共同决定；当每条提问只有一个相关块时，截断位次越大，精度上限越低，此时应当改用首中率或排序质量类的指标来反映真实表现。

３７　分母塌缩。当候选池的规模小于截断位次时，精度的分母会随之变小，使指标看起来偏高；因此评测语料的规模必须保证候选池大于截断位次，否则指标无法与更大语料下的结果比较。

３８　结束语（补充）。可复现、可审计、可比较，是评测体系的三个最低要求；三者缺一时，指标数字本身就会变成一种误导。

３９　评测与生产的同源。评测所用的检索路径必须与生产一致，否则测的是另一套系统；组合层、

包装层与运行期开关都要在评测中显式走同一条路径。

４０　改动前后的对照方法。评估一项改动时，两侧应当只在被考察的那一项上不同，其余条件保持一致；同时改动多项会让结论无法归因，即便指标变好也无法判断是哪一项起了作用。

４１　记录与留痕。每一次评测的数值、口径与代码版本都应写入报告，使事后可以回答这个数字是在什么条件下得到的；缺少口径的数字无法与后续版本比较。

４２　结束语（终）。本文所述的方法并不追求更高的指标数值，而是追求每一个数字都能被追溯、被复核、被比较。